

从零开始手写VIO 第三课作业

边城量子 2019.7.06

1. 样例代码给出了使用LM算法来估计曲线 $y = \exp(ax^2 + bx + c)$ 参数 a, b, c 的完整过程


- ① 请绘制样例代码中LM阻尼因子 μ 随着迭代变化的曲线图
- ② 将曲线函数改成 $y = ax^2 + bx + c$, 请修改样例代码中残差计算,雅可比计算等函数, 完成曲线参数估计.
- 如果有实现其他阻尼因子更新策略可加分(选做).

回答:

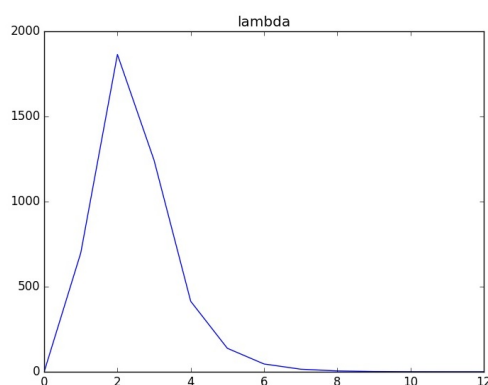
目标1: 绘制 μ 的随迭代变化的曲线图

- 1. 先说结论, 经过修改代码, 加入打点代码对Lambda输出, 编译执行, 然后 编写python代码画图输出曲线图, 曲线图如下:
 - 左图为输出了所有迭代过程中所有的点 (即while循环内部的currentLambda)的变化情况, 右图仅输出最终每次迭代的结果 (即仅仅在while循环结束后输出currentLambda);
 - 可以看出两者区别在于, 迭代内部还是经历了先变大后变小的过程的;

打印所有点(包括while循环内部调整的点)



仅打印while循环后的结果的点



- 2. 下面讲述整个修改代码, 编写Python的详细过程:
 - 1. 修改 problem.cc 代码, 对 currentLambda_ 的值进行打点并追加输出到 points.txt 文件, 修改后的 bool Problem::Solve() 函数如下:
备注: 如下代码仅展示了打印所有点的情况, 即上图的左图, 如果仅打印每次迭代结果, 把打点代码移动到while循环之外即可:

```
bool Problem::Solve(int iterations) {  
    if (edges_.size() == 0 || vertices_.size() == 0) {  
        std::cerr << "\nCannot solve problem without edges or  
vertices" << std::endl;  
        return false;  
    }  
}
```

```

TicToc t_solve;
// 统计优化变量的维数，为构建 H 矩阵做准备
SetOrdering();
// 遍历edge，构建  $H = J^T * J$  矩阵
MakeHessian();
// LM 初始化
ComputeLambdaInitLM();
// LM 算法迭代求解
bool stop = false;
int iter = 0;

// ----- 新增代码 Start -----
// 删除旧的数据文件
std::string fpath = "points.txt";
remove( fpath.c_str() );
// ----- 新增代码 End -----

while (!stop && (iter < iterations)) {
    std::cout << "iter: " << iter << " , chi= " << currentChi_ << "
, Lambda= " << currentLambda_
    << std::endl;

    bool oneStepSuccess = false;
    int false_cnt = 0;
    while (!oneStepSuccess) // 不断尝试 Lambda，直到成功迭代一步
    {
        // setLambda
        AddLambdatoHessianLM();

        // ----- 新增代码 Start -----
        // 对最新的lambda进行记录，记录到points.txt文件中
        ofstream fin( fpath , ios::app);
        fin << currentLambda_ << endl;
        // ----- 新增代码 End -----

        // 第四步，解线性方程  $H X = B$ 
        SolveLinearSystem();
        //
        RemoveLambdaHessianLM();

        // 优化退出条件1: delta_x_ 很小则退出
        if (delta_x_.squaredNorm() <= 1e-6 || false_cnt > 10) {
            stop = true;
            break;
        }

        // 更新状态量  $x = x + \text{delta}_x$ 
        UpdateStates();
        // 判断当前步是否可行以及 LM 的 lambda 怎么更新
        oneStepSuccess = IsGoodStepInLM();
        // 后续处理，
        if (oneStepSuccess) {
            // 在新线性化点 构建 hessian
            MakeHessian();
            false_cnt = 0;
        } else {
            false_cnt++;
        }
    }
}

```

```

        RollbackStates();    // 误差没下降, 回滚
    }
}
iter++;

    // 优化退出条件3: currentChi_ 跟第一次的chi2相比, 下降了 1e6 倍则退出
    if (sqrt(currentChi_) <= stopThresholdLM_)
        stop = true;
}
std::cout << "problem solve cost: " << t_solve.toc() << " ms" <<
std::endl;
std::cout << "    makeHessian cost: " << t_hessian_cost_ << " ms" <<
std::endl;
return true;
}

```

■ 2. 编译运行CurveFitting工程

建立 build 目录, 运行可执行程序, 生成 points.txt, 从程序输出可看出, 优化后的参数和真实值差别很小, 在1e-2级别:

```

mkdir build
cd build
cmake ..
make
cd app
./testCurveFitting

```

程序执行输出如下:

```

Test CurveFitting start...
iter: 0 , chi= 36048.3 , Lambda= 0.001
iter: 1 , chi= 30015.5 , Lambda= 699.051
iter: 2 , chi= 13421.2 , Lambda= 1864.14
iter: 3 , chi= 7273.96 , Lambda= 1242.76
iter: 4 , chi= 269.255 , Lambda= 414.252
iter: 5 , chi= 105.473 , Lambda= 138.084
iter: 6 , chi= 100.845 , Lambda= 46.028
iter: 7 , chi= 95.9439 , Lambda= 15.3427
iter: 8 , chi= 92.3017 , Lambda= 5.11423
iter: 9 , chi= 91.442 , Lambda= 1.70474
iter: 10 , chi= 91.3963 , Lambda= 0.568247
iter: 11 , chi= 91.3959 , Lambda= 0.378832
problem solve cost: 2.33059 ms
    makeHessian cost: 0.794637 ms
-----After optimization, we got these parameters :
    0.941939  2.09453  0.965586
-----ground truth:
1.0,  2.0,  1.0

```

■ 3. 编写一个python脚本 draw.py 用于绘制 points.txt 的点的折线图, 内容如下所示:

```
# coding: utf-8
```

```

# 绘图库
import matplotlib.pyplot as plt
import numpy as np

# lambda点保存路径
# 格式：每一行一个点
filename =
"/home/hadoop/Documents/CurveFitting_LM/build/app/points.txt"

# 保存点的列表
# points = []

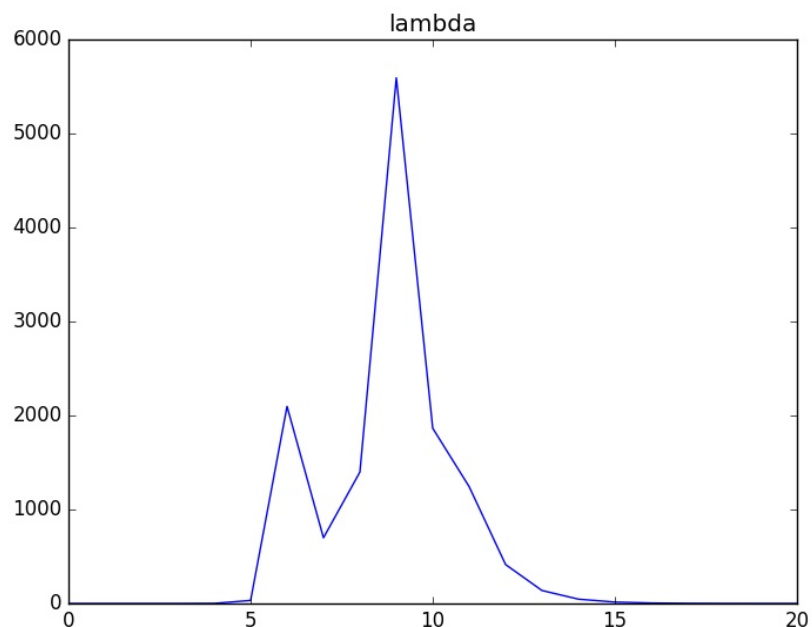
# 方式1：自己读取每一行，得到数据
# # 读取points
# with open(filename, 'r') as f:
#     lines = f.readlines()
#     for line in lines:
#         points.append(line)

# 方式2：使用np.loadtxt读取
points = np.loadtxt(filename)

# 绘图
plt.plot(points)
plt.title('lambda')
print("save to points.jpg")
plt.savefig('points.jpg')
plt.show()

```

- 4. 执行python脚本, lambda随迭代的变化图形如下:



- 目标2: 将曲线函数改成 $y = ax^2 + bx + c$, 请修改样例代码中残差计算,雅可比计算等函数, 完成曲线参数估计

- 1. 修改 CurveFitting.cpp 代码的 ComputeReisdual() 函数:

```

// 计算曲线模型误差
virtual void ComputeResidual() override
{
    Vec3 abc = verticies_[0]->Parameters(); // 估计的参数
    // 构建残差
    //residual_(0) = std::exp( abc(0)*x_*x_ + abc(1)*x_ + abc(2) )
- y_;
    // 残差函数为: ( ax^2 + bx + c ) - y_
    residual_(0) = abc(0)*x_*x_ + abc(1)*x_ + abc(2) - y_;
}

```

- 2. 修改 CurveFitting.cpp 代码的 ComputeJacobians() 函数:

```

// 计算残差对变量的雅克比
virtual void ComputeJacobians() override
{
    Vec3 abc = verticies_[0]->Parameters();
    double exp_y = std::exp( abc(0)*x_*x_ + abc(1)*x_ + abc(2) );

    Eigen::Matrix<double, 1, 3> jaco_abc; // 误差为1维, 状态量 3 个,
    所以是 1x3 的雅克比矩阵
    //jaco_abc << x_ * x_ * exp_y, x_ * exp_y, 1 * exp_y;
    // ax^2 + bx + c 分别对 a, b, c求偏导
    jaco_abc << x_*x_, x_, 1;
    jacobians_[0] = jaco_abc;
}

```

- 3. 修改 CurveFitting.cpp 代码的 main() 函数如下, 注意数据点个数N被修改到了 700, Lambda的曲线图会展示更多变化细节:

```

int main()
{
    double a=1.0, b=2.0, c=1.0; // 真实参数值
    int N = 700; // 数据点
    double w_sigma= 1.; // 噪声Sigma值

    std::default_random_engine generator;
    std::normal_distribution<double> noise(0.,w_sigma);

    // 构建 problem
    Problem problem(Problem::ProblemType::GENERIC_PROBLEM);
    shared_ptr< CurveFittingVertex > vertex(new
CurveFittingVertex());

    // 设定待估计参数 a, b, c初始值
    vertex->SetParameters(Eigen::Vector3d (0.,0.,0.));
    // 将待估计的参数加入最小二乘问题
    problem.AddVertex(vertex);

    // 构造 N 次观测
    for (int i = 0; i < N; ++i) {
        double x = i/100.;
        double n = noise(generator);
        // ----- 新增代码 Start -----
        // 观测 y
        //double y = std::exp( a*x*x + b*x + c ) + n;
    }
}

```

```

        double y = a*x*x + b*x + c + n*0.1;
        // ----- 新增代码 End -----

        // 每个观测对应的残差函数
        shared_ptr< CurveFittingEdge > edge(new
CurveFittingEdge(x,y));
        std::vector<std::shared_ptr<Vertex>> edge_vertex;
        edge_vertex.push_back(vertex);
        edge->SetVertex(edge_vertex);

        // 把这个残差添加到最小二乘问题
        problem.AddEdge(edge);
    }

    std::cout<<"\nTest CurveFitting start..."<<std::endl;
    /// 使用 LM 求解
    problem.Solve(30);

    std::cout << "-----After optimization, we got these
parameters :" << std::endl;
    std::cout << vertex->Parameters().transpose() << std::endl;
    std::cout << "-----ground truth: " << std::endl;
    std::cout << "1.0, 2.0, 1.0" << std::endl;

    // std
    return 0;
}

```


- 4. 输出如下, 可以看到优化后的参数和真实值差别很小, 在1.e-2级别:

```

Test CurveFitting start...
iter: 0 , chi= 653482 , Lambda= 3.34941
iter: 1 , chi= 696.818 , Lambda= 1.11647
iter: 2 , chi= 696.767 , Lambda= 0.372156
iter: 3 , chi= 696.767 , Lambda= 0.248104
problem solve cost: 2.10817 ms
    makeHessian cost: 1.35818 ms
-----After optimization, we got these parameters :
1.00191 1.98871 0.98923
-----ground truth:
1.0, 2.0, 1.0

```

- 5. 执行python脚本, lambda随迭代的变化图形如下:



- 目标3: 如果有实现其他阻尼因子更新策略可加分(选做).

- 1. 修改 `problem.cc` 中 `Problem::ComputeLambdaInitLM()` 函数, 使得 μ 具备两种初始化方式:

- 一种是使用Hessian矩阵对角线最大值作为初始值,
- 一种则是直接使用固定值为初始值

修改的局部代码如下:

```
double tau = 1e-5;  
// 初值策略1: 使用Hessian矩阵对角线上的最大值作为初始值  
currentLambda_ = tau * maxDiagonal;  
  
// 初值策略2: 使用固定值作为初始值  
//currentLambda_ = tau*0.1;
```

- 2. 修改 `problem.cc` 中 `Problem::IsGoodStepInLM()` 函数, 实现如下4种 μ 的更新方式:

- 策略1: Nielsen 阻尼因子更新策略, 即课件公式13

```
// rho > 0, lambda = lambda * max(1/3, 1-(2*rho - 1)^3); nu = 2  
// rho <=0, lambda = lambda * nu, nu = 2*nu;w
```

- 策略2: Marquardt 阻尼因子更新策略, 课件公式12

```
// rho < 0.25 , lambda = lambda*2.0  
// rho > 0.75 , lambda = lambda/3.0
```

- 策略3: Quadratic 阻尼因子更新策略, 参考 "The Levenberg-Marquardt algorithm for nonlinear least squares curve-fitting problems, Henri P. Gavin"

```
// h = delta_x*b
// diff = currentChi_ - tempChi;
// alpha = h / (0.5*diff + h )
// rho > 0, lambda = max( lambda/(1+alpha), 1.e-7)
// rho <=0, lambda = lambda + abs(diff*0.5/alpha)
```

- 策略4: 另外一种变形后的Levenberg 阻尼因子更新策略, 参考 "<http://www.duke.edu/~hpgavin/lm.m>"

```
// 9.0和11都是经验值, 控制lambda的增长/减少速度
// rho > 0, lambda = max( lambda/9.0, 1.e-7 )
// rho <=0, lambda = min( lambda*11, 1e7 )
```


- 3. 四种策略执行结果与Lambda随迭代变化曲线图比较如下:

针对 $ax^2 + bx + c$ 进行拟合 程序中其他参数:

int N = 700; 且 lambda 使用Hessian矩阵对角线上的最大值作为初始值

策略1: Nielsen 策略


4次迭代, Lambda最终约0.248, 多项式参数拟合误差 $<1e-2$



```
iter: 0 , chi= 653482 , Lambda= 3.34941
iter: 1 , chi= 696.818 , Lambda= 1.11647
iter: 2 , chi= 696.767 , Lambda= 0.372156
iter: 3 , chi= 696.767 , Lambda= 0.248104
problem solve cost: 2.30179 ms
makeHessian cost: 1.65904 ms
-----After optimization, we got these parameters :
1.00191 1.98871 0.98923
-----ground truth:
1.0, 2.0, 1.0
```

策略2: Marquardt 策略


3次迭代, Lambda最终约1.49, 多项式参数拟合误差 $<1e-2$



```
iter: 0 , chi= 653482 , Lambda= 3.34941
iter: 1 , chi= 696.772 , Lambda= 2.23294
iter: 2 , chi= 696.767 , Lambda= 1.48863
problem solve cost: 1.80488 ms
makeHessian cost: 1.21715 ms
-----After optimization, we got these parameters :
1.00191 1.98869 0.989258
-----ground truth:
1.0, 2.0, 1.0
```

策略3: Qudratic 策略


3次迭代, Lambda约为0.72, 多项式系数误差 $1e-02$



```
iter: 0 , chi= 653482 , Lambda= 3.34941
iter: 1 , chi= 696.818 , Lambda= 2.00965
iter: 2 , chi= 696.767 , Lambda= 1.20649
iter: 3 , chi= 696.767 , Lambda= 0.725779
problem solve cost: 2.46435 ms
makeHessian cost: 1.84593 ms
-----After optimization, we got these parameters :
1.00191 1.98871 0.989234
-----ground truth:
1.0, 2.0, 1.0
```

策略4: Levenberg 策略

3次迭代, Lambda约为0.041, 多项式系数误差 $<1e-2$



```
iter: 0 , chi= 653482 , Lambda= 3.34941
iter: 1 , chi= 696.818 , Lambda= 0.372156
iter: 2 , chi= 696.767 , Lambda= 0.0413507
problem solve cost: 1.59624 ms
makeHessian cost: 1.13543 ms
-----After optimization, we got these parameters :
1.00191 1.98869 0.989271
-----ground truth:
1.0, 2.0, 1.0
```


- 4. 四种更新方式的代码如下所示:

```
bool Problem::IsGoodStepInLM() {
    double scale = 0;
    // 对应课件公式11, 得到 scale = L(0) - L(delta_x)
    // currentLambda_ 即课件中的  $\mu$ 
    scale = delta_x_.transpose() * (currentLambda_ * delta_x_ + b_);
    scale += 1e-3;    // make sure it's non-zero :)

    // recompute residuals after update state
    // 统计所有的残差, 即公式10的分子部分的  $F(x+\delta x)$ 
    double tempChi = 0.0;
    for (auto edge: edges_) {
        edge.second->ComputeResidual();
        tempChi += edge.second->Chi2();
    }

    // 计算比例因子, 公式10 的rho
    double rho = (currentChi_ - tempChi) / scale;
    // 阻尼因子更新策略选择器 strategy ,有多种策略课选择
    int strategy = 4;
    switch ( strategy ) {
        case 1: // Nielsen 阻尼因子更新策略 , 即课件公式13
            // rho > 0, lambda = lambda * max(1/3, 1-(2*rho - 1)^3); nu = 2
            // rho <=0, lambda = lambda * nu, nu = 2*nu;w
            if (rho > 0 && isfinite(tempChi)) // last step was good, 误差在
下降
            {
                double alpha = 1. - pow((2 * rho - 1), 3);
                alpha = std::min(alpha, 2. / 3.);
                double scaleFactor = (std::max)(1. / 3., alpha);
                currentLambda_ *= scaleFactor;
                ni_ = 2;
                currentChi_ = tempChi;
                return true;
            } else {
                currentLambda_ *= ni_;
                ni_ *= 2;
                return false;
            }
        break;
        case 2: // Marquardt的阻尼策略, 课件公式12
            // rho < 0.25 , lambda = lambda*2.0
            // rho > 0.75 , lambda = lambda/3.0
            // 备注: 在本例中, 此方法无法优化得到合适的a,b,c的值
            if ( rho < 0.25 && isfinite(tempChi)) {
                currentLambda_ *= 2.0;
                currentChi_ = tempChi;
                return true;
            } else if ( rho > 0.75 && isfinite(tempChi) ) {
                currentLambda_ /= 3.0;
                currentChi_ = tempChi;
                return false;
            } else {
                // do nothing
                return false;
            }
    }
}
```

```

        break;
    case 3: // Quadratic策略
        //参见论文"The Levenberg-Marquardt algorithm for nonlinear least
        squares curve-fitting problems, Henri P. Gavin"
        // h = delta_x_*b
        // diff = currentChi_ - tempChi;
        // alpha = h / (0.5*diff + h )
        // rho > 0, lambda = max( lambde/(1+alpha), 1.e-7)
        // rho <=0, lambda = lambda + abs(diff*0.5/alpha)
        { // 代码块, 避免编译出现错误提示(本case块初始化变量进入下一个case)
            double h = delta_x_.transpose() * b_;
            double diff = currentChi_ - tempChi;
            double alpha_ = h / (0.5*diff + h);
            if ( rho > 0 && isfinite(tempChi) ){
                currentLambda_ = std::max(currentLambda_/(1+alpha_),
1.e-7 );
                currentChi_ = tempChi;
                return true;
            }else if( rho <=0 && isfinite(tempChi) ){
                currentLambda_ = currentLambda_ +
std::abs(diff*0.5/alpha_);
                currentChi_ = tempChi;
                return false;
            }
        }
        break;
    case 4: //Levenberg 策略
        // 参考"http://www.duke.edu/~hpgavin/lm.m"
        // 9.0和11都是经验值, 控制lambda的增长/减少速度
        // rho > 0, lambda = max( lambda/9.0, 1.e-7 )
        // rho <=0, lambda = min( lambda*11, 1e7 )
        if ( rho > 0 && isfinite(tempChi)) {
            currentLambda_ = std::max(currentLambda_/9.0, 1.e-7);
            currentChi_ = tempChi;
            return true;
        }else{
            currentLambda_ = std::min(currentLambda_*11, 1.e7);
            currentChi_ = tempChi;
            return false;
        }
        break;
    }
}
}

```

2. 公式推导,根据课程知识,完成F,G中如下两项的推导过程:

$$f_{15} = \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \delta \mathbf{b}_k^g} = -\frac{1}{4} (\mathbf{R}_{b_i b_{k+1}} [(\mathbf{a}^{b_k} - \mathbf{b}_k^a)]_{\times} \delta t^2) (-\delta t)$$

$$g_{12} = \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \mathbf{n}_k^g} = -\frac{1}{4} (\mathbf{R}_{b_i b_{k+1}} [(\mathbf{a}^{b_k} - \mathbf{b}_k^a)]_{\times} \delta t^2) \left(\frac{1}{2} \delta t \right)$$

回答1: f_{15} 推导:

其中分子 $\alpha_{b_i b_{k+1}} = \alpha_{b_i b_k} + \beta_{b_i b_k} \delta t + \frac{1}{2} a \delta t^2$,

由于是对k时刻的 δb_k^g 求导, 因此前两项均与它无关, 所以可略去。

第三项中的a可表示为: $a = \frac{1}{2} (q_{b_i b_k} (a^{b_k} + n_k^a - b_k^a) + q_{b_i b_{k+1}} (a^{b_{k+1}} + n_{k+1}^a - b_k^a))$, 其中前半部分在对 δb_k^g 求导时无关, 可略去; 后一项中的 n_{k+1}^g 已经被包含在 $a^{b_{k+1}}$ 中, 因此也略去;

因此 f_{15} 可变为如下形式, 然后加入右扰动 $\left[-\frac{1}{2} \delta \mathbf{b}_k^g \delta t \right]$ 并转化为旋转矩阵形式, 展开exp, 并利用叉乘性质交换顺序, 最后得到结果:

$$\begin{aligned}
 f_{15} &= \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \delta \mathbf{b}_k^g} \\
 &= \frac{1}{4} \frac{\partial \mathbf{q}_{b_i b_{k+1}} \otimes \left[-\frac{1}{2} \delta \mathbf{b}_k^g \delta t \right] (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \delta \mathbf{b}_k^g} \\
 &= \frac{1}{4} \frac{\partial \mathbf{R}_{b_i b_{k+1}} \exp \left(\left[-\delta \mathbf{b}_k^g \delta t \right]_{\times} \right) (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \delta \mathbf{b}_k^g} \\
 &\approx \frac{1}{4} \frac{\partial \mathbf{R}_{b_i b_{k+1}} (\mathbf{I} + \left[-\delta \mathbf{b}_k^g \delta t \right]_{\times}) (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \delta \mathbf{b}_k^g} \\
 &= \frac{1}{4} \frac{-\partial \mathbf{R}_{b_i b_{k+1}} \left[(\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \right]_{\times} \delta t^2 (-\delta \mathbf{b}_k^g \delta t)}{\partial \delta \mathbf{b}_k^g} \\
 &= -\frac{1}{4} (\mathbf{R}_{b_i b_{k+1}} \left[(\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \right]_{\times} \delta t^2) (-\delta t)
 \end{aligned} \tag{1}$$

回答2: g_{12} 推导:

其中分子 $\alpha_{b_i b_{k+1}} = \alpha_{b_i b_k} + \beta_{b_i b_k} \delta t + \frac{1}{2} a \delta t^2$,

由于是对k时刻的 \mathbf{n}_k^g 求导, 因此前两项均与它无关(和k-1时刻的 \mathbf{n}_{k-1}^g 有关), 因此可略去。

第三项中的a可表示为 $a = \frac{1}{2} (q_{b_i b_k} (a^{b_k} + n_k^a - b_k^a) + q_{b_i b_{k+1}} (a^{b_{k+1}} + n_{k+1}^a - b_k^a))$, 其中前半部分在对 \mathbf{n}_k^g 求导时无关, 可略去; 后一项中的 n_{k+1}^g 已经被包含在 $a^{b_{k+1}}$ 中, 因此也略去;

因此 g_{12} 可变为如下形式, 然后加入右扰动 $\left[\frac{1}{4} \mathbf{n}_k^g \delta t \right]$ 并转化为旋转矩阵形式, 展开exp, 并利用叉乘性质交换顺序, 最后得到结果:

$$\begin{aligned}
 g_{12} &= \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \mathbf{n}_k^g} \\
 &= \frac{1}{4} \frac{\partial \mathbf{q}_{b_i b_{k+1}} \otimes \left[\frac{1}{4} \mathbf{n}_k^g \delta t \right] (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \mathbf{n}_k^g} \\
 &= \frac{1}{4} \frac{\partial \mathbf{R}_{b_i b_{k+1}} \exp \left(\left[\frac{1}{2} \mathbf{n}_k^g \delta t \right]_{\times} \right) (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \mathbf{n}_k^g} \\
 &\approx \frac{1}{4} \frac{\partial \mathbf{R}_{b_i b_{k+1}} (\mathbf{I} + \left[\frac{1}{2} \mathbf{n}_k^g \delta t \right]_{\times}) (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \mathbf{n}_k^g} \\
 &= \frac{1}{4} \frac{\partial \mathbf{R}_{b_i b_{k+1}} \left[\frac{1}{2} \mathbf{n}_k^g \delta t \right]_{\times} (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \mathbf{n}_k^g} \\
 &= -\frac{1}{4} \frac{\partial \mathbf{R}_{b_i b_{k+1}} \left[(\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \right]_{\times} \delta t^2 \left(\frac{1}{2} \mathbf{n}_k^g \delta t \right)}{\partial \mathbf{n}_k^g} \\
 &= -\frac{1}{4} (\mathbf{R}_{b_i b_{k+1}} \left[(\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \right]_{\times} \delta t^2) \left(\frac{1}{2} \delta t \right)
 \end{aligned} \tag{2}$$

3. 证明式(9).

题目:

已知阻尼因子定义:

$$(\mathbf{J}^\top \mathbf{J} + \mu \mathbf{I}) \Delta \mathbf{x}_{lm} = -\mathbf{J}^\top \mathbf{f} \quad \text{with } \mu \geq 0 \quad (3)$$

阻尼因子 μ 大小是相对与 $\mathbf{J}^\top \mathbf{J}$ 的元素而言的。半正定的信息矩阵 $\mathbf{J}^\top \mathbf{J}$ 特征值 λ_j 和对应的特征向量为 \mathbf{v}_j 。对 $\mathbf{J}^\top \mathbf{J}$ 做特征值分解后有: $\mathbf{J}^\top \mathbf{J} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top$, 可得:

$$\Delta \mathbf{x}_{lm} = - \sum_{j=1}^n \frac{\mathbf{v}_j^\top \mathbf{F}'^\top}{\lambda_j + \mu} \mathbf{v}_j \quad (4)$$

回答:

由 $\mathbf{J}^\top \mathbf{J} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top$, 可知其为对称矩阵, 它有 n 个线性无关的特征向量, 设 λ_i 为特征值, $\mathbf{V} = (\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n)$, 其中 \mathbf{v}_i 是列向量, 是 n 个特征向量通过正交单位化得到的一组正交且模为1的向量, 可知 \mathbf{V} 为正交矩阵, $\mathbf{\Lambda}$ 为对角矩阵。

因此这个对称矩阵有如下性质 (利用了 正交矩阵 $\mathbf{V} \mathbf{V}^\top = \mathbf{I}$, 从而 $\mathbf{V}^{-1} = \mathbf{V}^\top$ 的性质):

$$(\mathbf{J}^\top \mathbf{J})^{-1} = (\mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top)^{-1} = (\mathbf{V}^\top)^{-1} \mathbf{\Lambda}^{-1} \mathbf{V}^{-1} = \mathbf{V} \mathbf{\Lambda}^{-1} \mathbf{V}^\top, \text{ 其中 } [\mathbf{\Lambda}^{-1}]_{ii} = \frac{1}{\lambda_i}$$

代入公式(4):

$$\begin{aligned} \Delta \mathbf{x}_{lm} &= (\mathbf{J}^\top \mathbf{J} + \mu \mathbf{I})^{-1} (-\mathbf{J}^\top \mathbf{f}) \\ &= (\mathbf{V} \text{diag}(\lambda_1 + \mu, \lambda_2 + \mu, \dots, \lambda_n + \mu) \mathbf{V}^\top)^{-1} (-\mathbf{J}^\top \mathbf{f}) \\ &= \mathbf{V} \text{diag} \left(\frac{1}{\lambda_1 + \mu}, \frac{1}{\lambda_2 + \mu}, \dots, \frac{1}{\lambda_n + \mu} \right) \mathbf{V}^\top (-\mathbf{J}^\top \mathbf{f}) \\ &= [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \dots \quad \mathbf{v}_n] \begin{bmatrix} \frac{1}{\lambda_1 + \mu} & 0 & \dots & 0 \\ 0 & \frac{1}{\lambda_2 + \mu} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & \dots & \frac{1}{\lambda_n + \mu} \end{bmatrix} \begin{bmatrix} \mathbf{v}_1^\top \\ \mathbf{v}_2^\top \\ \vdots \\ \mathbf{v}_n^\top \end{bmatrix} (-\mathbf{J}^\top \mathbf{f}) \\ &= - \sum_{j=1}^n \frac{\mathbf{v}_j^\top \mathbf{F}'^\top}{\lambda_j + \mu} \mathbf{v}_j \end{aligned}$$

最后一步推导过程说明:

使用矩阵乘法的结合律, 从右向左计算:

- $\mathbf{F}'^\top = \mathbf{J}^\top \mathbf{f}$ 是一个列向量, 而 \mathbf{v}_j^\top 是一个行向量, 所以相乘之后的量 $\mathbf{v}_j^\top \mathbf{F}'^\top$ 是一个标量, n 个标量 $\mathbf{v}_j^\top \mathbf{F}'^\top$ 组成的是一个新的列向量 $[\mathbf{v}_1^\top \mathbf{F}'^\top \quad \mathbf{v}_2^\top \mathbf{F}'^\top \quad \dots \quad \mathbf{v}_n^\top \mathbf{F}'^\top]$;
- 这个列向量再和前面的对角阵相乘后, 结果依然还是一个列向量, 列向量的每一项值是 $\frac{\mathbf{v}_j^\top \mathbf{F}'^\top}{\lambda_j + \mu}$;
- 这个列向量再和前面的矩阵 $[\mathbf{v}_1 \quad \mathbf{v}_2 \quad \dots \quad \mathbf{v}_n]$ 相乘, 乘出来每一项都是 $\frac{\mathbf{v}_j^\top \mathbf{F}'^\top}{\lambda_j + \mu} \mathbf{v}_j$, 写成求和形式即为:

$$\sum_{j=1}^n \frac{\mathbf{v}_j^\top \mathbf{F}'^\top}{\lambda_j + \mu} \mathbf{v}_j$$

- 再添上负号即为公式(9)